



Contents


Architettura di Sistema - Specifiche Complete	1
Diagramma Generale	1
Flusso di Esecuzione - Loop Principale	3
Interazione tra Componenti - Diagramma di Sequenza	4
Architettura Flussi Dati	5
Macchina a Stati - Stati di Esecuzione	7
Dipendenze tra Componenti	8
Architettura di Deployment	9
Caratteristiche di Performance	10
Breakdown Budget Latenza	10
Caratteristiche di Scalabilità	11

Architettura di Sistema - Specifiche Complete

Diagramma Generale







Flusso di Esecuzione - Loop Principale

```

INIZIO
|
+--> [1. RICEZIONE TASK]
|
|   |
|   +- Parse input
|   +- Validazione formato
|   +- Estrazione parametri
|   |
+--> [2. ANALISI GOAL]
|
|   |
|   +- Identificazione obiettivi
|   +- Estrazione vincoli
|   +- Definizione criteri successo
|   +- Classificazione complessità
|   |
+--> [3. RECUPERO CONTESTO]
|
|   |
|   +- Query episodic memory (task simili passati)
|   +- Controllo pattern cache (strategie apprese)
|   +- Caricamento working memory (sessione corrente)
|   |
+--> [4. PIANIFICAZIONE]
|
|   |
|   +- Generazione piano alto livello
|   +- Decomposizione in subtask
|   +- Identificazione dipendenze
|   +- Stima risorse (token, tempo, costo)
|   +- Selezione strategia esecuzione
|   |
+--> [5. LOOP ESECUZIONE]


```


```

|   |
|   +- PER ogni step nel piano:
|   |
|   |   +-> [5a. Pre-esecuzione]
|   |   |       +- Verifica sicurezza
|   |   |       +- Controllo risorse
|   |   |       +- Decisione routing modello
|   |
|   |   +-> [5b. Esecuzione]
|   |   |       +- Reasoning LLM (se necessario)
|   |   |       +- Esecuzione tool (se necessario)
|   |   |       +- Cattura output
|   |
|   |   +-> [5c. Post-esecuzione]
|   |   |       +- Verifica risultato
|   |   |       +- Controllo criteri successo
|   |   |       +- Aggiornamento working memory
|   |
|   |   +-> [5d. Adattamento]
|   |   |       +- Se successo: Continua
|   |   |       +- Se fallimento: Strategia recovery
|   |   |       +- Se bloccato: Ripianificazione
|   |
+-> [6. VERIFICA]
|
|   +- Validazione output finale
|   +- Controllo criteri successo
|   +- Verifica sicurezza finale
|
+-> [7. REFLECTION]
|
|   +- Analisi performance episodio
|   +- Estrazione pattern di successo
|   +- Identificazione miglioramenti
|   +- Aggiornamento pattern cache
|   +- Memorizzazione in episodic memory
|
+-> [8. RESTITUZIONE RISULTATO]


```


Interazione tra Componenti - Diagramma di Sequenza






Architettura Flussi Dati







OUTPUT	RISULTATO
+	-----+


Macchina a Stati - Stati di Esecuzione






Dipendenze tra Componenti





Architettura di Deployment



	+-----+-----+	
+-----+-----+		
TIER CACHE		
+-----+-----+		
Redis / Memcached		
(Pattern Cache, Stato Sessione)		
+-----+-----+		
+-----+-----+		
TIER DATI		
+-----+-----+-----+-----+		
PostgreSQL Pinecone S3/Blob		
(Metadata) (Episodic (Log,		
Memory) Artifact)		
+-----+-----+-----+-----+		
+-----+-----+		
+-----+-----+		
SERVIZI ESTERNI		
+-----+-----+-----+		
Anthropic OpenAI Tool		
Claude GPT-4 Custom		
+-----+-----+-----+		
+-----+-----+		
+-----+-----+		
OBSERVABILITY		
+-----+-----+-----+		
Prometheus Grafana ELK		
(Metriche) (Dashboard) (Log)		
+-----+-----+-----+		

Caratteristiche di Performance

Breakdown Budget Latenza

Target Totale: 5-30s per task complessità media

+-----+-----+-----+-----+		
Componente	Tempo	% Totale

Analisi Goal	0.5s	2%	
Recupero Contesto	1.0s	5%	
Pianificazione	2.0s	10%	
Esecuzione:			
- Chiamate model	15.0s	70%	
- Esecuzione tool	3.0s	13%	
Verifica	0.5s	2%	
Reflection	1.0s	5%	
+-----+-----+-----+			
TOTALE	~23s	~100%	
+-----+-----+-----+			

Strategie di ottimizzazione:

- Routing modelli (usa modelli veloci quando sufficiente)
- Esecuzione parallela tool
- Riuso pattern cached
- Streaming per latenza percepita

Caratteristiche di Scalabilità

Dimensione	Corrente	Target	Strategia	Scaling
Utenti Concurrent	10-50	100-500	Orizzontale	
Task/Ora	100-500	5K-10K	Orizzontale	
Episodi Memory	10K	1M+	Scala Vector DB	
Pattern Cache	1K	10K+	Cache distribuita	
Latenza Media	5-30s	<30s	Ottimizz. modelli	
Success Rate	85-95%	>90%	Apprendimento cont.	

Prossimo: 02-cognitive-layer.md -> Specifiche dettagliate dei componenti di ragionamento