Contents

Guida al Deployment: Operazioni in Produzione

Panoramica

Questo documento fornisce una guida per il deployment e l'operatività del Reflective Adaptive Agent in produzione, coprendo modelli di deployment, strategie di scaling, monitoraggio e best practice operazionali.

1. Modelli di Deployment

1.1 Architetture di Deployment

Tre Modelli Principali di Deployment:

```
+-------------------------------------------------------------+
|           COMPARAZIONE MODELLI DI DEPLOYMENT                |
|                                                             |
|  Modello 1: SINGLE-TENANT (Un'istanza per cliente)          |
|  +-------------------------------------------------------+ |
|  |  Cliente A          Cliente B          Cliente C      | |
|  |  +----------+       +----------+       +----------+   | |
|  |  | Istanza  |       | Istanza  |       | Istanza  |   | |
```

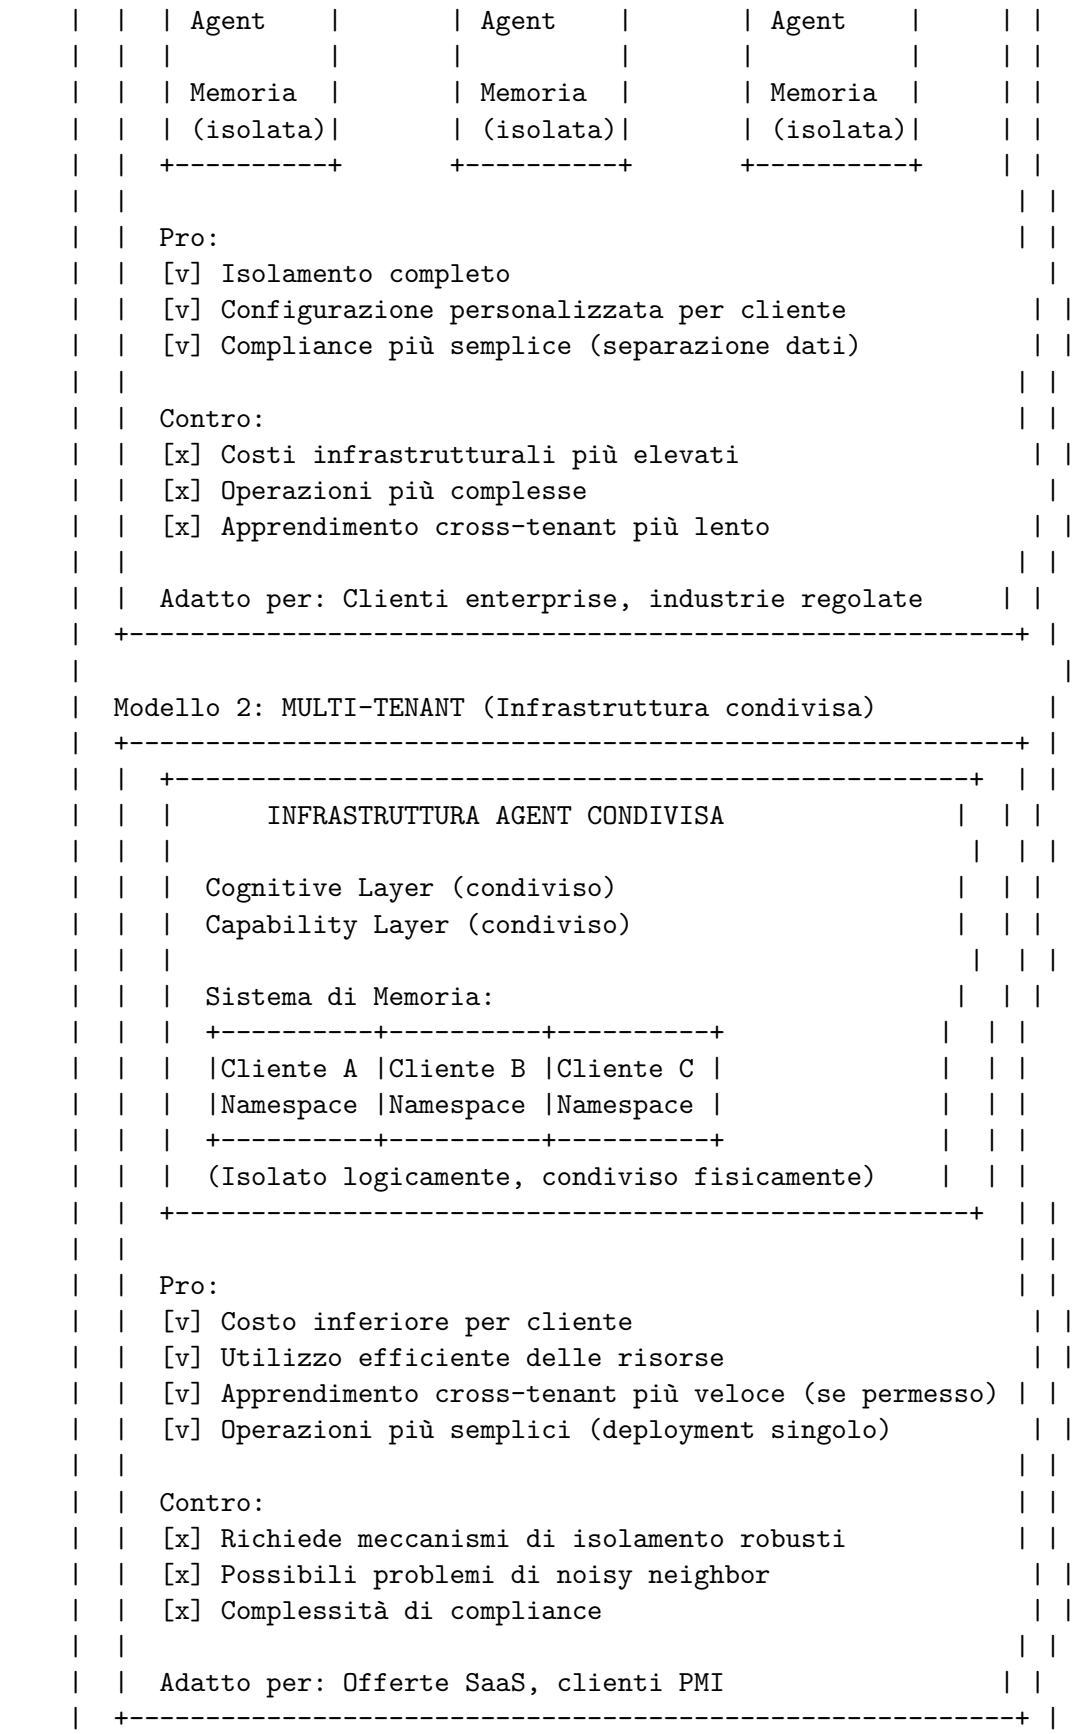
Agent
Memoria
(isolata)
Agent
Memoria
(isolata)
Agent
Memoria
(isolata)
Pro:
[v] Isolamento completo
[v] Configurazione personalizzata per cliente
[v] Compliance più semplice (separazione dati)
Contro:
[x] Costi infrastrutturali più elevati
[x] Operazioni più complesse
[x] Apprendimento cross-tenant più lento
Adatto per: Clienti enterprise, industrie regolate
Modello 2: MULTI-TENANT (Infrastruttura condivisa)
INFRASTRUTTURA AGENT CONDIVISA
Cognitive Layer (condiviso)
Capability Layer (condiviso)
Sistema di Memoria:
|Cliente A |Cliente B |Cliente C |
|Namespace |Namespace |Namespace |
(Isolato logicamente, condiviso fisicamente)
Pro:
[v] Costo inferiore per cliente
[v] Utilizzo efficiente delle risorse
[v] Apprendimento cross-tenant più veloce (se permesso)
[v] Operazioni più semplici (deployment singolo)
Contro:
[x] Richiede meccanismi di isolamento robusti
[x] Possibili problemi di noisy neighbor
[x] Complessità di compliance
Adatto per: Offerte SaaS, clienti PMI

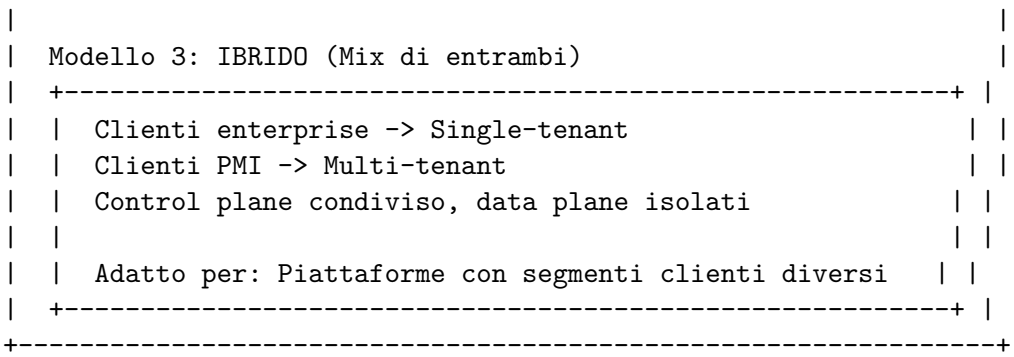

1.2 Componenti Infrastrutturali

Mappa di Deployment dei Componenti:

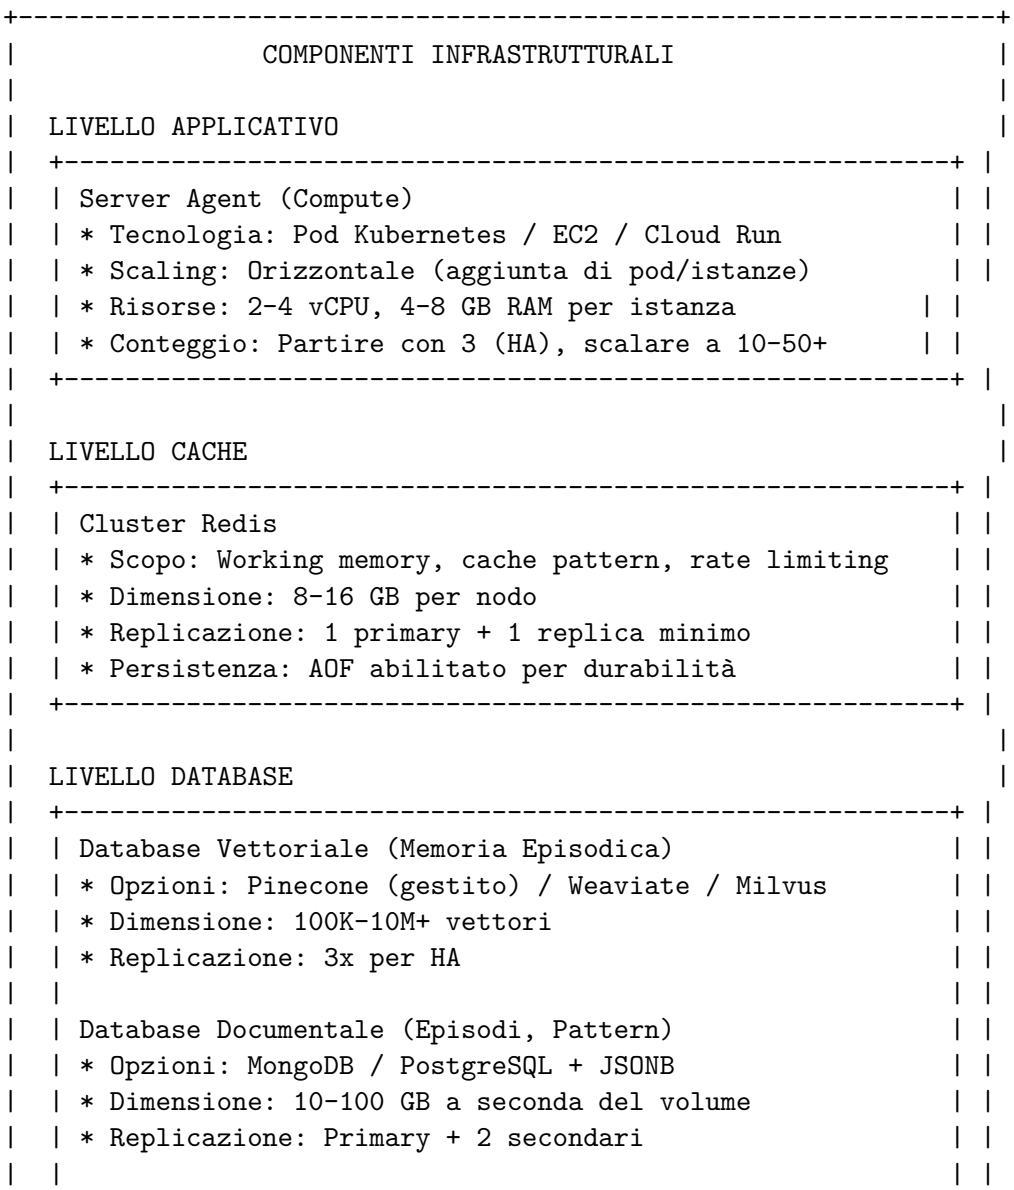

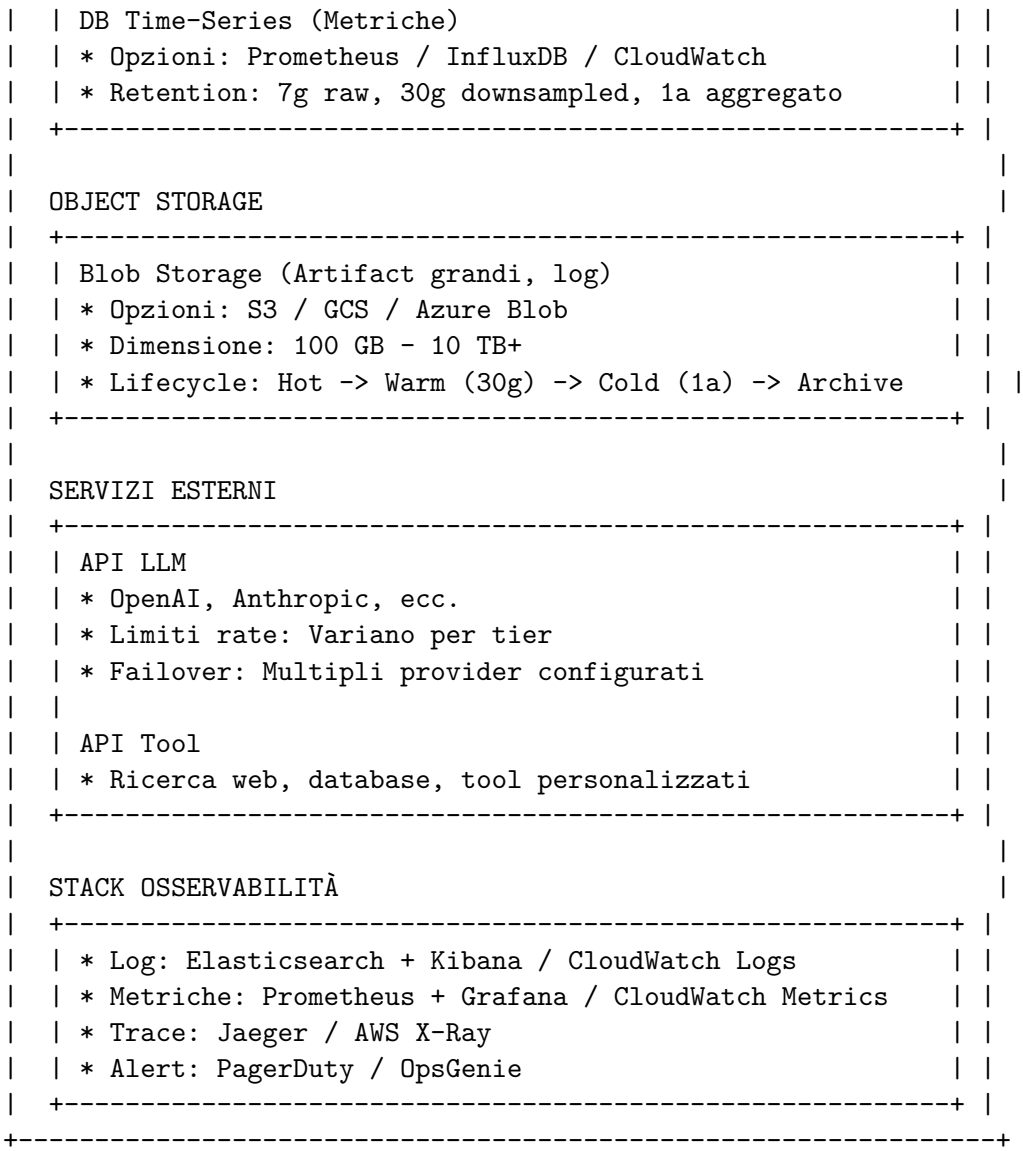

2. Strategie di Scaling

2.1 Scaling Orizzontale

Scaling del Livello Applicativo:

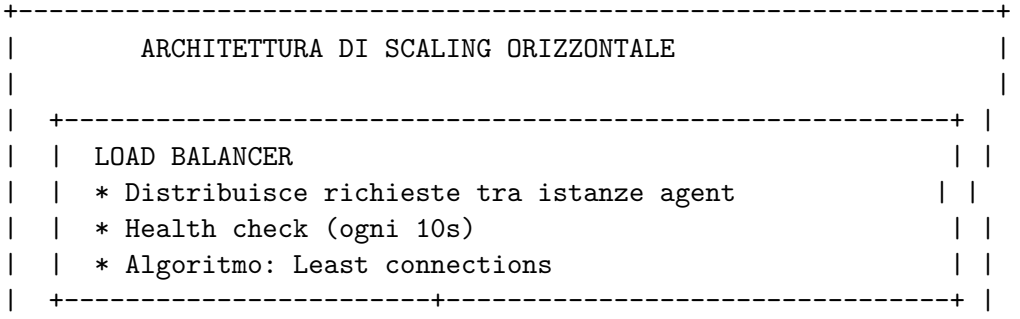

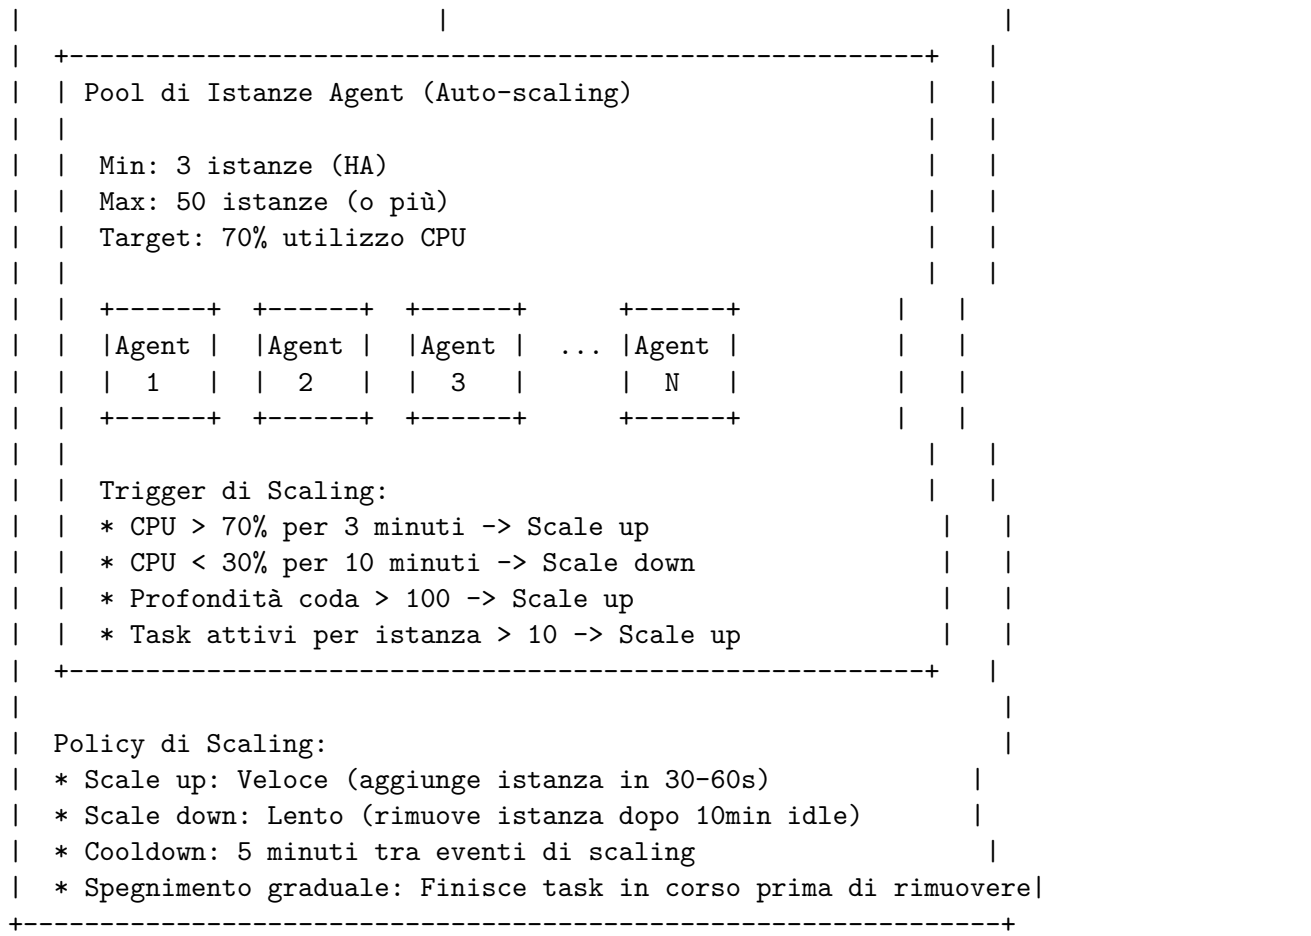

Algoritmo di Decisione per lo Scaling:

```
Function AUTO_SCALE():

  # Ogni 1 minuto
  current_metrics = GET_METRICS(window="5min")

  # Calcola segnali di scaling
  cpu_signal = current_metrics.cpu_avg / TARGET_CPU  # > 1 = scale up
  memory_signal = current_metrics.memory_avg / TARGET_MEMORY
  queue_signal = current_metrics.queue_depth / TARGET_QUEUE_DEPTH
  concurrency_signal = current_metrics.tasks_per_instance / TARGET_TASKS_PER_INSTANCE

  # Combinazione pesata
  scale_signal = (
    0.4 * cpu_signal +
    0.2 * memory_signal +
    0.2 * queue_signal +
    0.2 * concurrency_signal
  )

  # Decisione
```

```
  IF scale_signal > 1.3:
    # Significativamente sopra capacità
    desired_instances = current_instances * 1.5  # Scale up aggressivo
  ELSE IF scale_signal > 1.1:
    # Leggermente sopra capacità
    desired_instances = current_instances + 1  # Scale up graduale
  ELSE IF scale_signal < 0.5:
    # Significativamente sotto capacità
    desired_instances = current_instances * 0.7  # Scale down aggressivo
  ELSE IF scale_signal < 0.7:
    # Leggermente sotto capacità
    desired_instances = current_instances - 1  # Scale down graduale
  ELSE:
    # Nel range target
    desired_instances = current_instances  # Nessun cambio

  # Applica vincoli
  desired_instances = CLAMP(desired_instances, MIN_INSTANCES, MAX_INSTANCES)

  # Esegui se diverso e cooldown trascorso
  IF desired_instances != current_instances AND COOLDOWN_ELAPSED():
    SCALE_TO(desired_instances)
    LOG_INFO(f"Scaling da {current_instances} a {desired_instances}")
```

2.2 Scaling dei Database

Scaling del Database Vettoriale:

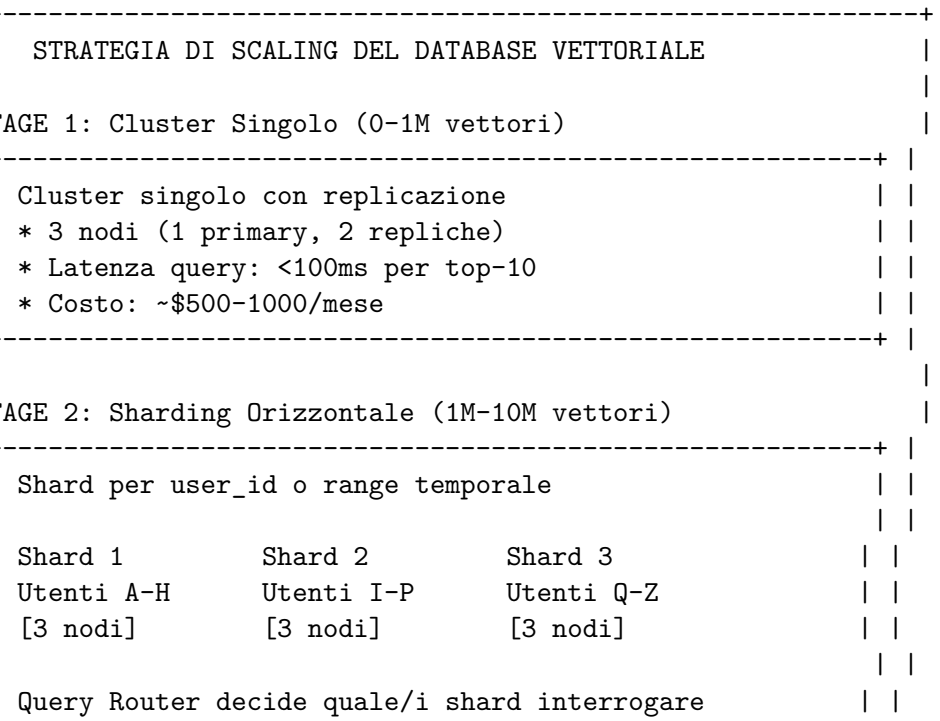

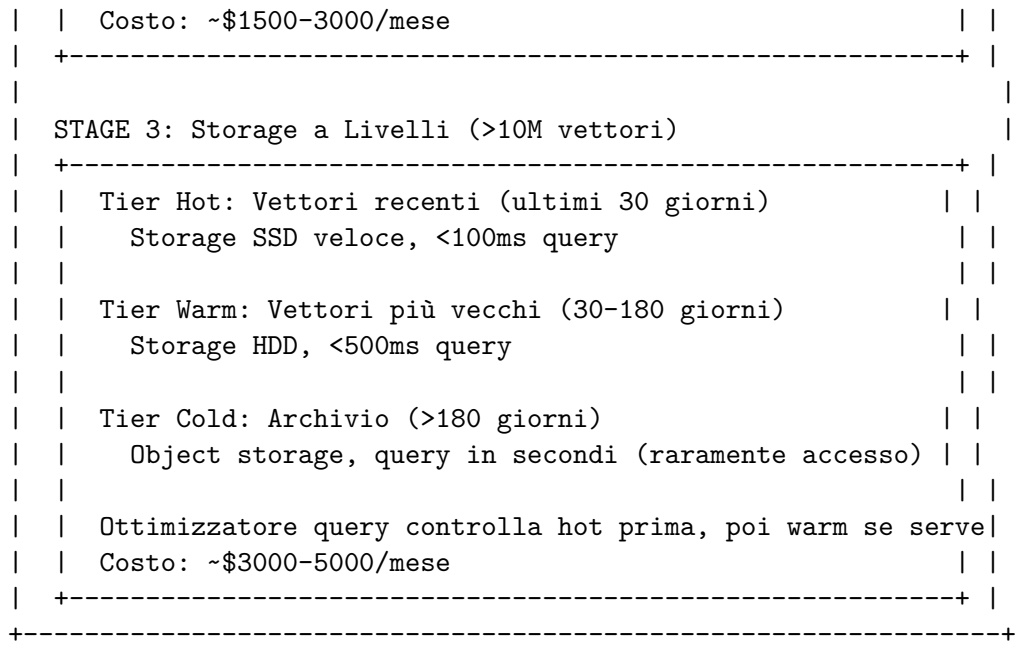

Scaling del Database Documentale:

Opzioni:

```
1. SCALING VERTICALE (Più semplice, limitato)
   * Aumenta dimensione istanza (CPU, RAM, IOPS)
   * Funziona fino a ~1TB dati, ~1000 QPS
   * Costo: Prevedibile, ~$500-2000/mese

2. READ REPLICA (Per carico read-heavy)
   * 1 primary (scritture) + N repliche (letture)
   * Instrada query memoria episodica alle repliche
   * Funziona fino a ~5000 QPS lettura
   * Costo: ~$1000-3000/mese

3. SHARDING (Per write-heavy o dati grandi)
   * Shard per user_id o range temporale
   * Ogni shard è database indipendente
   * Routing a livello applicativo
   * Funziona fino a 10TB+ dati
   * Costo: ~$3000-10000/mese
```

3. Alta Disponibilità

3.1 Architettura HA

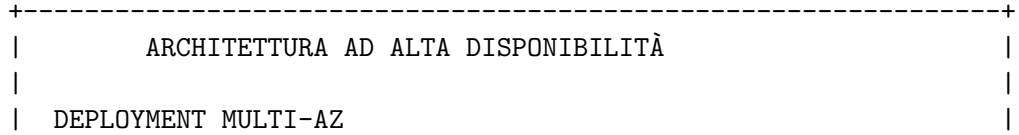

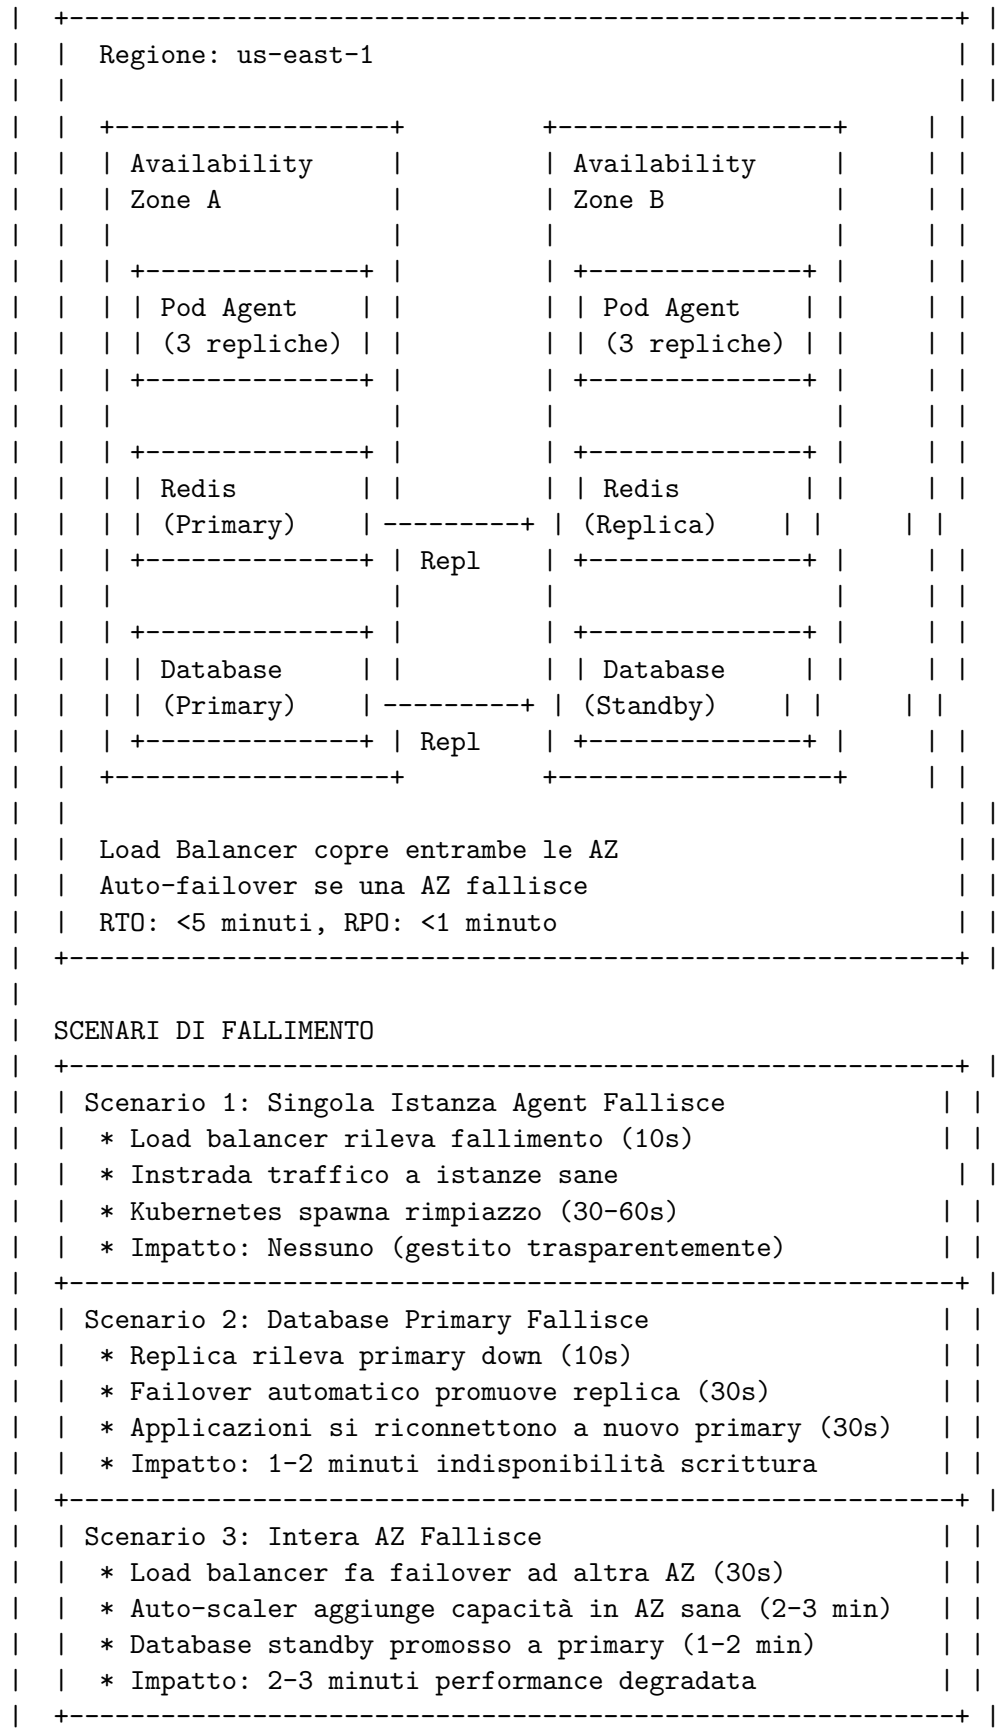
Regione: us-east-1
Availability Zone A
Pod Agent (3 repliche)
Redis (Primary)
Database (Primary)
Repl
Availability Zone B
Pod Agent (3 repliche)
Redis (Replica)
Database (Standby)
Load Balancer copre entrambe le AZ
Auto-failover se una AZ fallisce
RTO: <5 minuti, RPO: <1 minuto
SCENARI DI FALLIMENTO
Scenario 1: Singola Istanza Agent Fallisce
* Load balancer rileva fallimento (10s)
* Instrada traffico a istanze sane
* Kubernetes spawna rimpiazzo (30-60s)
* Impatto: Nessuno (gestito trasparentemente)
Scenario 2: Database Primary Fallisce
* Replica rileva primary down (10s)
* Failover automatico promuove replica (30s)
* Applicazioni si riconnettono a nuovo primary (30s)
* Impatto: 1-2 minuti indisponibilità scrittura
Scenario 3: Intera AZ Fallisce
* Load balancer fa failover ad altra AZ (30s)
* Auto-scaler aggiunge capacità in AZ sana (2-3 min)
* Database standby promosso a primary (1-2 min)
* Impatto: 2-3 minuti performance degradata

```
|  | Scenario 4: API LLM Non Disponibile                    | |
|  |  * Model router rileva fallimento (5-10s)              | |
|  |  * Fallback a provider alternativo (immediato)         | |
|  |  * Impatto: Minimo (gestito da catena fallback)        | |
|  +--------------------------------------------------------+ |
+-------------------------------------------------------------+
```

3.2 Disaster Recovery

Strategia di Backup:

```
+-------------------------------------------------------------+
|              STRATEGIA DI BACKUP E RECOVERY                 |
|                                                             |
|  DATABASE                                                   |
|  +--------------------------------------------------------+ |
|  | Replicazione Continua                                  | |
|  |  * Primary -> Standby (sincrona)                       | |
|  |  * RPO: <1 minuto                                      | |
|  |                                                        | |
|  | Snapshot Automatici                                    | |
|  |  * Frequenza: Ogni 6 ore                               | |
|  |  * Retention: 7 giorni (28 snapshot)                   | |
|  |  * Tempo di restore: 10-30 minuti                      | |
|  |                                                        | |
|  | Backup Long-term                                       | |
|  |  * Frequenza: Settimanale                              | |
|  |  * Retention: 1 anno                                   | |
|  |  * Storage: Tier archive più economico                 | |
|  +--------------------------------------------------------+ |
|                                                             |
|  OBJECT STORAGE (S3/GCS)                                    |
|  +--------------------------------------------------------+ |
|  | Versioning Abilitato                                   | |
|  |  * Tutti gli oggetti versionati                        | |
|  |  * Può recuperare da cancellazione accidentale         | |
|  |  * Retention versioni: 30 giorni                       | |
|  |                                                        | |
|  | Replicazione Cross-Region                              | |
|  |  * Dati critici replicati in altra regione             | |
|  |  * Asincrona (ritardo minuti)                          | |
|  |  * Per scenari disaster recovery                       | |
|  +--------------------------------------------------------+ |
|                                                             |
|  CONFIGURAZIONE                                             |
|  +--------------------------------------------------------+ |
|  | Infrastructure as Code (IaC)                           | |
|  |  * Tutta l'infrastruttura definita in Terraform/CloudFormation|
```

```
|  |  * Version control in Git                                    | |
|  |  * Può ricostruire intero stack da codice                    | |
|  |                                                              | |
|  | Configuration Management                                     | |
|  |  * Secret in vault dedicato (HashiCorp Vault / AWS Secrets)| |
|  |  * Config applicazione in version control                    | |
|  |  * Può ripristinare configurazione rapidamente               | |
|  +--------------------------------------------------------------+ |
|                                                                    |
|  OBIETTIVI DI TEMPO DI RECOVERY                                    |
|  +--------------------------------------------------------------+ |
|  | RTO (Recovery Time Objective):                               | |
|  |  * Sistemi critici: 15 minuti                                | |
|  |  * Sistemi non critici: 4 ore                                | |
|  |                                                              | |
|  | RPO (Recovery Point Objective):                              | |
|  |  * Dati critici: 1 minuto (replicazione continua)            | |
|  |  * Dati non critici: 6 ore (basato su snapshot)              | |
|  +--------------------------------------------------------------+ |
+--------------------------------------------------------------------+
```

4. Monitoraggio e Alerting

4.1 Setup di Monitoraggio in Produzione

Gerarchia Dashboard di Monitoraggio:

```
+--------------------------------------------------------------------+
|           STRUTTURA DASHBOARD DI MONITORAGGIO                      |
|                                                                    |
|  LIVELLO 1: DASHBOARD EXECUTIVE (KPI alto livello)                 |
|  +--------------------------------------------------------------+ |
|  | * Stato Sistema: [OK] Operativo                              | |
|  | * Tasso Successo: 91.3% (Target: >90%)                       | |
|  | * Latenza P95: 28s (Target: <30s)                            | |
|  | * Costo per Task: $0.17 (Budget: $0.30)                      | |
|  | * Utenti Attivi: 245                                         | |
|  | * Task Oggi: 1,832                                           | |
|  +--------------------------------------------------------------+ |
|                                                                    |
|  LIVELLO 2: DASHBOARD OPERATIVA (Salute componenti)                |
|  +--------------------------------------------------------------+ |
|  | Stato Componenti:                                            | |
|  | [OK] Istanze Agent (12/12 sane)                              | |
|  | [OK] Cache Redis (hit rate: 78%)                             | |
|  | [OK] DB Vettoriale (latenza: 85ms)                           | |
|  | [OK] DB Documentale (connessioni: 45/100)                    | |
|  | [!] Model Router (tasso fallback: 8%)                        | |
```

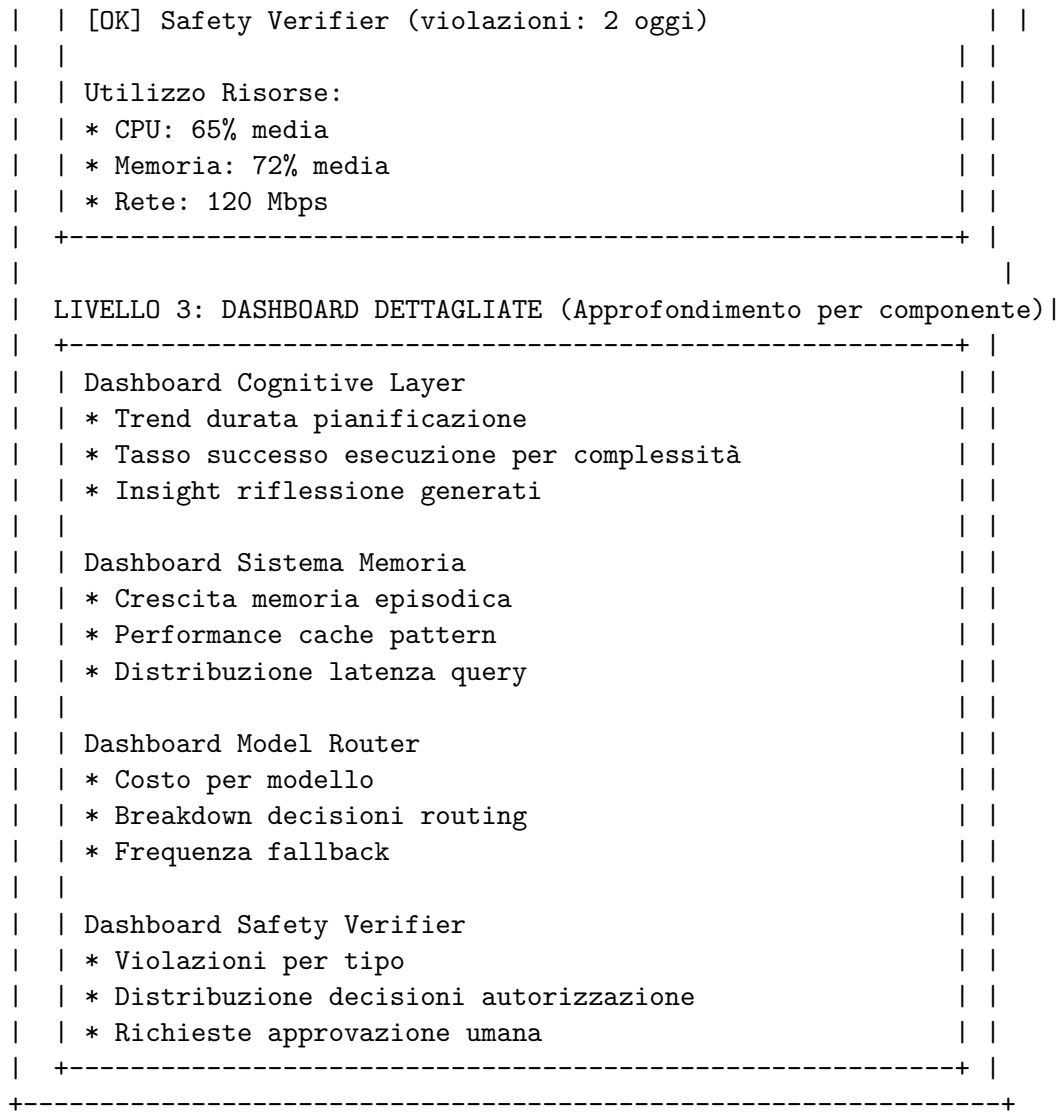

4.2 Configurazione Alert

Matrice di Severità Alert:

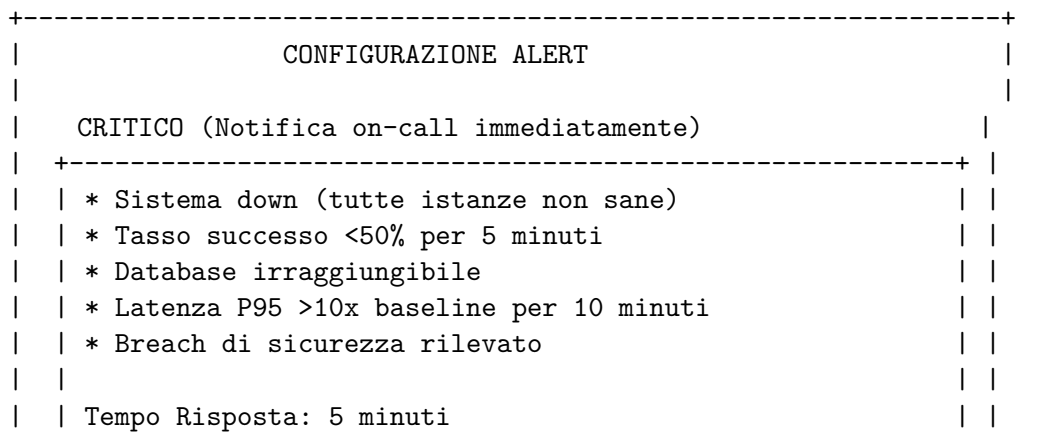

```
|  | Notifica: Chiamata telefonica + SMS + Slack              | |
|  +----------------------------------------------------------+ |
|                                                                |
|   ALTO (Investigare entro 30 minuti)                          |
|  +----------------------------------------------------------+ |
|  | * Tasso successo <80% per 15 minuti                      | |
|  | * Latenza P95 >2x baseline per 15 minuti                 | |
|  | * Tasso errore >25% per 10 minuti                        | |
|  | * Uso memoria >90% per 10 minuti                         | |
|  | * Lag replica database >5 minuti                         | |
|  |                                                          | |
|  | Tempo Risposta: 30 minuti                                | |
|  | Notifica: Slack + Email                                  | |
|  +----------------------------------------------------------+ |
|                                                                |
|   MEDIO (Investigare entro 2 ore)                             |
|  +----------------------------------------------------------+ |
|  | * Tasso successo <90% per 30 minuti                      | |
|  | * Costo per task >150% del budget                        | |
|  | * Cache hit rate <50% per 30 minuti                      | |
|  | * Tasso fallback modello >15% per 30 minuti              | |
|  | * Uso disco >80%                                         | |
|  |                                                          | |
|  | Tempo Risposta: 2 ore                                    | |
|  | Notifica: Slack                                          | |
|  +----------------------------------------------------------+ |
|                                                                |
|   BASSO (Revisione durante orario lavorativo)                 |
|  +----------------------------------------------------------+ |
|  | * Tasso successo <95% per 1 ora                          | |
|  | * Nuovi tipi di errore che appaiono                      | |
|  | * Trend lento di degradazione                            | |
|  | * Certificato in scadenza tra 30 giorni                  | |
|  |                                                          | |
|  | Tempo Risposta: Prossimo giorno lavorativo               | |
|  | Notifica: Email                                          | |
|  +----------------------------------------------------------+ |
+----------------------------------------------------------------+
```

5. Playbook Operativi

5.1 Risposte a Incidenti Comuni

Playbook: Tasso di Errore Elevato

```
SINTOMI:
* Tasso errore >20% per 10+ minuti
* Tasso successo in rapido calo
```

```
* Utenti che riportano fallimenti

PASSI DI INVESTIGAZIONE:
1. Controlla dashboard: Quale componente sta fallendo?
2. Rivedi deployment recenti: Cambiamenti nell'ultima ora?
3. Controlla dipendenze esterne: Stato API LLM, database
4. Rivedi log errori: Quali tipi di errore stanno occorrendo?
5. Controlla utilizzo risorse: Esaurimento risorse?

STRATEGIE DI RISOLUZIONE:

SE API esterna down:
  -> Abilita provider fallback
  -> Aggiorna pagina stato
  -> Stima tempo risoluzione da provider

SE problemi connessione database:
  -> Controlla impostazioni connection pool
  -> Aumenta max connessioni se necessario
  -> Considera failover read replica

SE relato a deployment:
  -> Rollback a versione precedente
  -> Investiga problema offline
  -> Deploya fix quando pronto

SE esaurimento risorse:
  -> Scale up immediatamente
  -> Investiga resource leak
  -> Deploya fix se necessario

COMUNICAZIONE:
* Aggiorna pagina stato entro 5 minuti
* Posta su canale Slack clienti
* Invia email se outage >30 minuti
```

Playbook: Latenza Elevata

```
SINTOMI:
* Latenza P95 >2x normale
* Utenti che riportano risposta lenta
* Timeout task in aumento

INVESTIGAZIONE:
1. Identifica componente bottleneck (da tracing)
2. Controlla utilizzo risorse (CPU, memoria, rete)
3. Rivedi pattern traffico recenti (picco?)
4. Controlla performance query database
5. Controlla latenza API esterne
```

```
RISOLUZIONE:

SE picco traffico:
  -> Scale up per gestire carico
  -> Considera rate limiting se abusivo

SE database lento:
  -> Controlla query lente (abilita query logging)
  -> Aggiungi indici se mancanti
  -> Considera routing read replica

SE API modello lenta:
  -> Controlla se provider ha problemi
  -> Instrada a tier modello più veloce temporaneamente
  -> Abilita caching aggressivo

SE sistema memoria lento:
  -> Controlla performance DB vettoriale
  -> Considera cache warming
  -> Aggiungi più nodi DB vettoriale

PREVENZIONE:
* Imposta scaling predittivo
* Cache aggressiva
* Implementa circuit breaker
```

5.2 Operazioni di Manutenzione

Task di Manutenzione Routinaria:

```
GIORNALIERO:
 Rivedi alert notturni
 Controlla completamento backup
 Rivedi trend tasso errore
 Controlla trend utilizzo risorse

SETTIMANALE:
 Rivedi risultati validazione cache pattern
 Analizza trend costi
 Controlla vulnerabilità sicurezza
 Rivedi log query lente
 Testa ripristino backup (campionamento)

MENSILE:
 Rivedi proiezioni capacity planning
 Aggiorna soglie scaling se necessario
 Rivedi e archivia vecchi log
```

```
  Aggiorna documentazione
  Drill disaster recovery
  Audit sicurezza

TRIMESTRALE:
  Review sicurezza comprensiva
  Benchmarking performance
  Review ottimizzazione costi
  Aggiorna dipendenze e patch
  Review architettura
```

6. Ottimizzazione Costi

6.1 Breakdown Costi

Costi Mensili Tipici (per ~10K task/giorno):

```
+-------------------------------------------------------------+
|               BREAKDOWN COSTI MENSILI                       |
|                                                             |
|  COMPUTE (Server Agent)                          $800       |
|  * 10 istanze @ $80/mese ciascuna                           |
|  * Auto-scaling tra 5-15 istanze                            |
|                                                             |
|  API LLM (Costo maggiore)                        $3,500     |
|  * ~$0.18 per task media                                    |
|  * 10K task/giorno * 30 giorni * $0.18                      |
|  * Ottimizzato via model routing                            |
|                                                             |
|  DATABASE                                        $1,200     |
|  * DB Vettoriale: $600                                      |
|  * DB Documentale: $400                                     |
|  * DB Time-series: $200                                     |
|                                                             |
|  CACHE (Redis)                                   $300       |
|  * Cluster 16GB con replicazione                            |
|                                                             |
|  OBJECT STORAGE                                  $150       |
|  * S3 per log, artifact                                     |
|                                                             |
|  OSSERVABILITÀ                                   $250       |
|  * Storage log, metriche, trace                             |
|  * Grafana Cloud / Datadog                                  |
|                                                             |
|  NETWORKING                                      $200       |
|  * Load balancer, data transfer                             |
|                                                             |
|  ---------------------------------------------------       |
```

```
|  TOTALE                                              $6,400/mese   |
|                                                                    |
|  Costo per task: $6,400 / 300K task = $0.021                       |
|  (Più costi LLM di ~$0.18 = $0.201 totale per task)                |
+--------------------------------------------------------------------+
```

6.2 Strategie di Ottimizzazione Costi

```
+--------------------------------------------------------------------+
|         STRATEGIE DI OTTIMIZZAZIONE COSTI                          |
|                                                                    |
|  1. MODEL ROUTING (Impatto maggiore: ~50% riduzione costi LLM)|
|     * Usa modelli appropriati al tier                              |
|     * Modelli piccoli per task semplici                            |
|     * Monitora e regola pesi routing                               |
|                                                                     |
|  2. CACHING (Impatto: ~20% riduzione costi)                         |
|     * Cache recuperi pattern                                       |
|     * Cache query memoria episodica                                |
|     * Cache risposte LLM per query ripetute                        |
|                                                                    |
|  3. RIGHTSIZING RISORSE (Impatto: ~15% costi infrastruttura)  |
|     * Monitora uso effettivo vs provisionato                       |
|     * Riduci dimensione risorse sovra-provvisionate                |
|     * Usa spot instance per workload non critici                   |
|                                                                    |
|  4. LIFECYCLE STORAGE (Impatto: ~30% costi storage)           |
|     * Sposta vecchi log a storage più economico                    |
|     * Archivia vecchi episodi in cold storage                      |
|     * Elimina dati veramente obsoleti                              |
|                                                                    |
|  5. CAPACITÀ RISERVATA (Impatto: ~20-40% costi infrastruttura)|
|     * Istanze riservate per capacità baseline                      |
|     * On-demand per burst                                          |
|     * Commitment 1 anno sicuri per workload stabilizzato           |
|                                                                    |
|  RISPARMIO TOTALE POTENZIALE: ~40-50% con tutte ottimizzazioni|
+--------------------------------------------------------------------+
```

7. Best Practice di Sicurezza

7.1 Checklist Sicurezza

```
SICUREZZA RETE:
  Tutti componenti in subnet private
  Load balancer unico componente pubblico
  Security group limitano traffico a porte necessarie
  TLS 1.3 per tutta comunicazione esterna
```

```
  Comunicazione interna criptata (mTLS)

AUTENTICAZIONE E AUTORIZZAZIONE:
  Autenticazione API richiesta (chiavi API o OAuth)
  Controllo accesso basato su ruoli (RBAC) implementato
  Principio least privilege applicato
  Account servizio per comunicazione inter-componente
  Rotazione credenziali regolare

PROTEZIONE DATI:
  Crittografia at rest per tutti i database
  Crittografia in transit per tutta comunicazione
  Rilevamento e mascheramento PII
  Audit logging di tutti accessi dati
  Policy retention dati applicate

SICUREZZA APPLICATIVA:
  Validazione input su tutti endpoint
  Output encoding per prevenire XSS
  Prevenzione SQL injection (query parametrizzate)
  Rate limiting per prevenire abusi
  Security header configurati

SICUREZZA OPERATIVA:
  Schedule patching sicurezza (mensile)
  Vulnerability scanning (settimanale)
  Penetration testing (trimestrale)
  Piano risposta incidenti sicurezza
  Training sicurezza dipendenti

COMPLIANCE:
  Compliance SOC 2 Type II (se applicabile)
  Compliance GDPR per clienti EU
  Audit compliance regolari
  Accordi trattamento dati con clienti
```

8. Conclusione

Questa guida al deployment fornisce le fondamenta per operare il Reflective Adaptive Agent in produzione. Punti chiave:

Inizia Semplice: Comincia con deployment single-tenant o small multi-tenant, scala quando necessario.

Monitora Tutto: Osservabilità comprensiva è essenziale per operare sistemi ML.

Automatizza Operazioni: Usa IaC, auto-scaling, backup automatizzati per ridurre carico operativo.

Pianifica per il Fallimento: Architettura HA, disaster recovery, playbook incidenti non sono opzionali.

Ottimizza Continuamente: Monitora costi e performance, ottimizza basandosi su pattern di uso effettivi.

Sicurezza Prima di Tutto: Implementa best practice sicurezza dal primo giorno, non come ripensamento.

Architettura di Riferimento Completa

Tutti gli 8 documenti core ora forniti: 1. [OK] Architettura di Sistema 2. [OK] Cognitive Layer 3. [OK] Sistema di Memoria 4. [OK] Capability Layer 5. [OK] Infrastruttura 6. [OK] Flussi di Dati 7. [OK] Rationale delle Decisioni 8. [OK] Guida al Deployment

Pronto per l'implementazione.